


Karte 6 · EKS, Karpenter und Spot

Eine Streaming-Plattform fährt ihre Microservices kostenoptimal: unkritische Pods auf Spot, kritische auf On-Demand — und ein sauberer Umgang mit der Spot-Kündigung



Ablauf Schritt für Schritt

- 1 Der Developer deployt, der kube-scheduler findet keine Kapazität
- 2 Karpenter liest die echten Anforderungen der Pending Pods
- 3 Für unterbrechbare Pods startet er Nodes aus dem Spot NodePool
- 4 EC2 kündigt die Spot-Node ~2 Minuten vorher an, EventBridge fängt es
- 5 Die Rule legt die Kündigung in die SQS Interruption Queue

- 6 Kritische und stateful Pods laufen im On-Demand NodePool
 - 7 Karpenter drainiert die Node und startet rechtzeitig Ersatz
- Fehlt Spot-Kapazität, fällt Karpenter automatisch auf On-Demand zurück
- Sinkt die Auslastung, packt Karpenter die Pods auf weniger Nodes
- Cluster Autoscaler skaliert nur vordefinierte Node Groups — entweder/oder