


Karte 10 · AWS Batch, EC2 GPU und S3

Ein Animationsstudio rendert nachts hunderte unabhängige Szenen: GPU-Jobs in einer Queue, Kapazität auf Spot, tagsüber keine Kosten — und ein Retry, wenn Spot zurückgeholt wird



Ablauf Schritt für Schritt

- 1 Das Render-Team schickt hunderte Jobs per submit-job an AWS Batch
- 2 Batch dispatcht den Job, der seine Szenen aus dem Input-Bucket zieht
- 3 Gerendert wird auf GPU-Instanzen der p-Familie, die Kapazität läuft auf Spot
- 4 Fertige Frames landen im Output-Bucket, per Lifecycle später im Archiv
- 5 Wird eine Spot-Instanz zurückgeholt, meldet EC2 das zwei Minuten vorher

- 6 Batch plant den betroffenen Job automatisch neu — kein Frame geht verloren
- Nach dem letzten Job fährt Batch auf 0 Instanzen herunter (minvCpus 0)
Fargate kann kein GPU — GPU-Jobs brauchen das EC2-Compute-Environment
Lambda scheidet aus: 15 Minuten Timeout und ebenfalls keine GPU