


Szenario 57 · Naechtlliche CSV-nach-Parquet-Transformation mit Glue ETL

40 Speditionspartner liefern jede Nacht CSV — der Job soll nur die neuen Dateien anfassen, ohne Server und ohne eigenen Spark-Cluster



Ablauf Schritt für Schritt

- 1 Die 40 Partner legen ihre CSV-Dateien in der Raw-Zone ab
- 2 Der Crawler liest Stichproben aus den neuen Dateien
- 3 Er traegt Tabelle und Partitionen in den Katalog ein
- 4 Der Job liest die Quelle ueber den Katalog, nicht per Pfad

- 5 Verarbeitet wird nur das Delta — als Parquet, nach Datum
 - 6 Dieselbe Athena-Abfrage kostet jetzt einen Bruchteil
 - 7 Der Job fragt vorher den Zustand des letzten Laufs ab
- Ohne transformation_ctx am Source-Node liest der Job jede Nacht alles