


Szenario 67 · SageMaker Training und Real-time Endpoints

Der Training Job ist Rechenzeit auf Abruf, der Endpoint ist Dauerbetrieb und kostet auch bei null Anfragen — dimensioniert wird er in der Endpoint Config, nicht im Training



Ablauf Schritt für Schritt

- 1 Historische Schadensfälle liegen als Trainingsdaten in S3
- 2 Der Training Job bekommt den S3-Pfad als Input-Channel
- 3 Er schreibt model.tar.gz nach S3, daraus entsteht das Model
- 4 Die Endpoint Config legt Instanztyp und Instanzzahl fest
- 5 Aus ihr entsteht der Real-time Endpoint

- 6 Die Anwendung ruft den Endpoint per HTTPS auf
 - 7 Application Auto Scaling regelt über InvocationsPerInstance
- Der Training Job kostet auf Zeit, der Endpoint kostet dauerhaft
Payload über 6 MB oder Laufzeit über 60 s heißt Async oder Batch
Model Monitor ist ab 30.07.2026 für Neukunden geschlossen