


Szenario 68 · Interner Chatbot auf Firmendokumenten (RAG)

Knowledge Bases decken den ganzen RAG-Weg ab: kein Modelltraining, kein eigener Sync — und die Quellenangabe funktioniert nur, weil das Mapping erhalten bleibt



Ablauf Schritt für Schritt

- 1 Die Knowledge Base zieht aus S3, Confluence und weiteren Quellen

2 Ein Ingestion Job hält den Vektorindex mit der Quelle synchron

3 Bedrock zerlegt in Chunks und rechnet die Embeddings — managed

4 Die Vektoren liegen in einer OpenSearch-Serverless-Collection

5 RetrieveAndGenerate sucht und generiert in einem einzigen Aufruf
- 6 Der Chatbot bekommt die Antwort samt Quellenangabe

7 Verworfen: der Selbstbau betriebe Sync und Indexpflege selbst

Fine-Tuning wäre falsch, sobald die Dokumente sich laufend ändern

Ein Agent wird erst gebraucht, wenn das System handeln soll